Procesamiento del lenguaje natural



Trabajo práctico número 3

Año 2026

Integrantes:

- ***Aiup Agustin***
- ***Ferreira da Camara Facundo***
- ***Paoloni Franco***
- ***Silva Julian***

1. ¿Qué detectores usamos en la auditoría, qué contaminación encontró cada uno y qué costo tiene un falso positivo?

Dividimos la muestra etiquetada por libro (350 de desarrollo y 150 de prueba, con 30 contaminados). Los detectores se calibraron solo sobre desarrollo y se midieron una vez sobre prueba:

detector	qué contaminación encuentra	precisión	recall
2.1 Regex (URL, dominio sin protocolo, correo, teléfono)	Enlaces y contactos visibles	1,00	0,40
2.2 Regex sobre texto normalizado	Enlaces disimulados: invisibles, homoglifos cirílicos, letras espaciadas, «punto»/«barra» escritos con palabras	1,00	0,63
2.3 Idioma por oración (langdetect, 8 palabras mín.)	Mensajes en inglés o portugués dentro de una sinopsis en castellano	0,89	0,27
2.5 Clasificador de oraciones (TF-IDF + reg. logística)	Texto promocional, incluso sin enlace	1,00	0,93
2.6 Vecino por coseno + contención	Libros inventados que copian la sinopsis de otro	1,00	0,10
Combinación (alcanza con que uno marque)	**Los cinco tipos completos**	**0,97**	**1,00**

Ningún detector solo pasa de recall 0,93: se combinan porque sus errores son distintos. El NER (2.4) quedó afuera. Su mejor variante da precisión 0,07 contra un piso de azar de 0,042, así que sirve para explicar el spam (nombra marcas inventadas), pero no para detectarlo. Sobre el catálogo completo el sistema marcó 407 de 8591 libros (4,7 %): 273 por texto promocional, 200 por enlace o contacto, 112 por idioma y 62 copias; quedaron 8184 en catalogo_limpio.csv.

Costo de un falso positivo: cada libro legítimo marcado sale del catálogo y el recomendador nunca lo va a poder sugerir. Además, el lector valora sobre el catálogo limpio, así que ese libro desaparece antes de que llegue a verlo. Lo medimos sobre los 497 libros de la muestra: el sistema encuentra 98 de 98 contaminados y se lleva 2 limpios de 399 (0,5 %), unas cuatro decenas de libros si se extrapola al catálogo. Por eso elegimos patrones conservadores, como exigir el dominio en minúscula. La precisión real va a ser menor que la medida, porque la muestra está enriquecida al 20 % de contaminados.

2. ¿Qué representa la etiqueta interes y quién realizó las valoraciones?

Interés es la respuesta del lector a «¿me interesaría leer este libro?» después de leer solo el título y la sinopsis: 1 = sí, 0 = no, vacío = no puede decidir. Representa un interés declarado a priori, no si el libro le gustó después de leerlo. Todas las valoraciones las hizo una sola persona, Julián Silva, recorriendo el catálogo limpio en el orden de sample(frac=1, random_state=42), sin saltear libros y antes de ver ninguna predicción.

Valoró 200 libros: 29 con 1 y 171 con 0, sin abstenciones. La tasa de positivos (14,5 %) condiciona todo lo que sigue: la parte de prueba tiene 40 libros con apenas 6 positivos.

3. ¿Cómo se compararon TF-IDF y embeddings en las dos tareas? ¿Dónde fue mayor la diferencia y por qué?

Detectar contaminación (clasificador de oraciones, a igual precisión, cerca de 0,90). Sobre prueba gana TF-IDF: precisión 1,00 y recall 0,93, contra 0,90 y 0,90. Pero 29 de los 30 contaminados de prueba usan una plantilla que el modelo ya vio en desarrollo, así que prueba mide memorización. Cuando armamos los pliegues por plantilla, para que cada frase sea nueva para el modelo, el resultado se invierte: recall 0,67 TF-IDF contra 0,89 embeddings. Casi toda la diferencia está en un tipo:

Frase nueva, por tipo	Enlace visible	Enlace disfrazado	Caract. ocultos	Copia	Promocional sin enlace
TF-IDF	31/33	10/13	6/6	11/11	9/37
embeddings	33/33	10/13	6/6	11/11	29/37

Para el catálogo nos quedamos con TF-IDF de todos modos. Sobre los 500 etiquetados las dos versiones de la combinación encuentran 100 de 100, y la de embeddings se lleva 8 libros limpios contra 4. Donde TF-IDF falla con una frase nueva, casi siempre hay además un enlace, un idioma ajeno o una copia que delata al libro.

Clasificar preferencias (160 libros de entrenamiento, 40 de prueba). Con el umbral de 0,5 los dos fracasan. TF-IDF no marca ningún libro (F1 de la clase 1 = 0,000, también en los 50 pliegues de validación) y embeddings da F1 0,167 (validado 0,132 ± 0,155). Los dos quedan por debajo del piso de marcar todo con 1 (F1 0,261). Como ordenadores, en cambio, empatan: precisión promedio validada 0,286 contra 0,287, el doble del azar (0,144). La matriz TF-IDF tiene 160 × 6845 términos con 1,4 % de celdas no nulas, contra 160 × 512 de los embeddings.

La diferencia fue mayor al detectar contaminación, y la razón es el tipo de señal. El texto promocional es una categoría de sentido: «conseguí este título en la app X» y «leé miles de libros sin publicidad» no comparten palabras. Los embeddings relacionan paráfrasis y TF-IDF solo reconoce términos literales. En las preferencias, el límite no está en la representación sino en los datos: 23 positivos repartidos en cuatro o cinco temas no alcanzan para aprender un criterio, se lea el texto como se lea.

4. ¿Algún clasificador mejoró las recomendaciones por similitud?

Sí, los dos, sobre todo el de embeddings, aunque la mejora es chica. Sobre la partición del enunciado, precision@5 dio 0,40 para TF-IDF y 0,20 tanto para embeddings como para la similitud con el perfil (azar 0,15). Con cinco libros, esa diferencia es un solo libro, así que repetimos la medición en 50 particiones:

Lista	Precision@5 (50 particiones)	Particiones bajo el azar (0,145)
B · embeddings + clasificador	**0,252 ± 0,149**	6 de 50

A · TF-IDF + clasificador	0,196 ± 0,130	11 de 50
C · similitud al perfil (promedio de los positivos)	0,160 ± 0,160	21 de 50

El perfil prácticamente elige al azar porque supone que lo que le gusta al lector es un punto del espacio. Medido, los 29 positivos son más dispersos entre sí (similitud media 0,184) que los negativos (0,198): divulgación científica, historia, IA y ensayo no están cerca unos de otros, y su promedio cae en un centro vacío. Un clasificador, en cambio, aprende qué distingue a un libro interesante y puede usar rasgos distintos para cada tema.

5. ¿Qué error encontramos y qué límite tiene el experimento?

El error. De las cinco recomendaciones del catálogo completo, Julián marcó tres como de interés: Guerras, soldados y máquinas, Ciencia: lo que hay que saber y El secreto de la vida. El tercer puesto fue Geno y su cocina, un recetario navarro, y él no lo eligió. Tiene explicación: entre los 23 positivos de entrenamiento hay dos recetarios (Mis mejores recetas y 100 fórmulas de salsas), y el modelo generalizó «cocina» como interés a partir de dos ejemplos. En prueba vimos el mismo problema del otro lado. Los dos libros de inteligencia artificial fueron falsos negativos (probabilidades 0,471 y 0,428), aunque la IA es uno de sus temas, porque casi no había libros de IA valorados con 1 para aprender. Y Historias del crepúsculo y lo desconocido apareció en las tres listas del paso 7 sin interesarle: cuando tres métodos fallan igual, el problema está en los datos.

Los límites. (1) Pocos datos: con 6 positivos en prueba, un libro mueve el recall 17 puntos y precision@5 tiene un desvío del tamaño de las diferencias entre métodos. Tres veces (plantillas en 2.5, AUC en 6.4 y precision@5 en 7.2) una sola partición dijo lo contrario que la medición repetida. (2) Un solo lector, que juzga por la sinopsis y no por la lectura, así que el modelo aprende un gusto declarado y no se puede generalizar a otras personas. (3) El modelo de embeddings corta en 128 tokens y el 83 % de las sinopsis entra truncada. (4) En la auditoría, la muestra reutiliza plantillas (sobreestima a TF-IDF) y está enriquecida al 20 % (sobreestima la precisión), y la calibración del 2.3 consultó la parte de prueba más de una vez. (5) Las recomendaciones del catálogo no tienen etiqueta: los 3 de 5 de Julián son una revisión humana, no una métrica comparable con la del paso 7.

Uso de asistentes de IA

Usamos Claude (Claude Code) para entender conceptos de la unidad, revisar y depurar código del notebook.