

Procesamiento del lenguaje natural



Trabajo práctico número 2

Año 2026

Integrantes:

- ***Aiup Agustin***
- ***Ferreira da Camara Facundo***
- ***Paoloni Franco***
- ***Silva Julian***

1. Selección de modelo para producción y justificación

Modelo seleccionado: Sentence-BERT (distiluse-base-multilingual-cased-v1) o una arquitectura híbrida en dos etapas.

Justificación:

- **Calidad y Métrica:** SBERT superó ampliamente a los demás enfoques con un $P@5 = 0.477$ y $P@3 = 0.487$, siendo el único capaz de resolver intención semántica pura sin coincidencia léxica.
- **Costo computacional y latencia:** Aunque inferir embeddings densos mediante transformers requiere mayor cómputo que TF-IDF en producción el catálogo de libros se precomputa e indexa una sola vez offline. En tiempo real (online), la inferencia ocurre sobre la consulta individual (típicamente < 15 tokens), lo que toma unos pocos milisegundos en CPU.
- **Privacidad y Dependencia de terceros:** distiluse es un modelo de código abierto ejecutable de manera local, eliminando la dependencia de APIs externas comerciales, costos por token y riesgos de fuga de datos o privacidad.
- **Reproducibilidad y Mantenimiento:** Los embeddings generados son deterministas, no requieren reentrenamiento ante adiciones al catálogo y generalizan a múltiples idiomas sin necesidad de diccionarios específicos.

2. Comparación frente a la línea de base (TF-IDF): ganancias y excepciones

Desempeño relativo

En promedio global sobre las 13 consultas, SBERT supera en más del doble a TF-IDF ($P@5$ de 0.477 frente a 0.200, y $P@3$ de 0.487 frente a 0.282). Frente a la línea de base aleatoria (piso empírico de ~ 0.045), SBERT multiplica por $10 \times$ el azar, mientras que TF-IDF lo supera por $4.4 \times$.

¿Dónde gana la semántica?

SBERT domina en consultas formuladas en lenguaje natural abstracto, temático o conceptual que no comparten el vocabulario de las sinopsis (q01 guerra, q04 crimen, q07 y q08 amor/desamor con $P@5 = 1.0$, donde TF-IDF obtuvo 0.0).

¿Dónde TF-IDF empata o gana?

En consultas con solapamiento léxico directo (q06 "poder político", q09 "emigrar", q13 "adolescencia y paso a la vida adulta", donde TF-IDF alcanzó 0.6 vs. 0.2 de SBERT).

Cuando las palabras de la consulta coinciden literalmente con las palabras clave distintivas de la sinopsis, el cálculo de IDF asigna un peso exacto y contundente sin introducir "ruido semántico". En esos casos, el modelo denso no paga la ventaja semántica porque no hay brecha de vocabulario que salvar.

El caso de Word2Vec (SBW)

Promediar vectores de palabra estáticos demostró ser ineficaz para documentos largos: el histograma de pares reveló un colapso del espacio (media 0.898 – 0.958 y desvío mínimo de 0.02 – 0.04), lo que genera rankings planos y frágiles que apenas alcanzan un $P@5 = 0.323$.

3. Alcance y limitaciones de la métrica (Precision@k)

¿Qué mide?

Mide la densidad o pureza de documentos relevantes en los primeros k resultados devueltos ($k \in \{3,5,10\}$). Evalúa directamente la experiencia de usuario inmediata (lo que ve el lector en la primera página de búsqueda).

¿Qué no mide?

- **Exhaustividad:** No informa cuántos documentos relevantes del total del corpus quedaron fuera del top- k (ignora los falsos negativos).
- **Ordenamiento interno:** Un acierto en la posición #1 aporta exactamente lo mismo que un acierto en la posición #5 dentro de $P@5$. Para evaluar la posición se requerirían métricas como MRR (Mean Reciprocal Rank) o NDCG.
- **Diversidad y Novedad:** No penaliza que los resultados sean redundantes o de la misma saga (problema abordado en la Parte 6).

El efecto de la prevalencia (R) y el piso de azar:

La cota superior de $P@k$ está condicionada por la cantidad de relevantes reales (R). En consultas con $R = 2$ (q09 y q11), el máximo teórico posible para $P@5$ es $2/5 = 0.40$.

El cálculo del piso aleatorio mediante permutaciones (~ 0.045) fue fundamental para certificar que un valor modesto (como el 0.20 de TF-IDF) representa señal informativa genuina y no ruido.

4. Análisis de un caso concreto de falla

Consulta analizada: q09 ("emigrar a otro país para empezar de nuevo lejos de casa").

En q09, los relevantes anotados en el catálogo eran solo dos ($R = 2$): Me llevaré el fuego (id = 84) y La enjuta (id = 3).

Resultado: SBERT obtuvo $P@5 = 0.20$ (recuperó únicamente Me llevaré el fuego en la posición #3), mientras que TF-IDF obtuvo $P@5 = 0.40$ (recuperó ambos relevantes en el top-5).

Hipótesis técnica de la causa:

- Filtro de longitud y truncamiento: El 84.2% de las sinopsis del corpus supera el límite de 128 tokens de SBERT. Si la mención explícita al viaje o al exilio se encontraba hacia el final del texto, el mecanismo de atención la descartó pasivamente.
- Dilución contextual en la atención global: Al generar un embedding único para todo el párrafo, SBERT priorizó la atmósfera melodramática general del argumento por sobre el concepto puntual de "emigrar", mientras que TF-IDF asignó un peso matemático directo al término exacto país y exilio.

5. Extensión avanzada: Sistema de recomendación y serendipia (Parte 6)

Al implementar "Más libros como este" a partir del libro semilla Crimen y castigo (I) (id = 31), la similitud coseno directa devolvió de inmediato Crimen y castigo (II) con similitud 1.000.

Este resultado es matemáticamente óptimo pero nulo en valor de negocio o recomendación (redundancia obvia).

Al aplicar filtros de exclusión (misma saga/serie y mismo autor), el espacio de SBERT recuperó obras temáticamente afines de autores distintos: “Las víctimas de Georges Bernanos” (crimen, culpa y atmósfera trágica) y “Una hora mala la tiene cualquiera...” de Hoyos y Vinent (deslices morales), garantizando serendipia y descubrimiento real en producción.

6. Declaración sobre el uso de Asistentes de IA

Se utilizó asistencia de modelos de lenguaje (IA) como soporte interactivo para la estructuración del código en Python, la depuración de funciones auxiliares de preprocesamiento, la consulta de sintaxis de librerías (gensim, sentence-transformers, scikit-learn). Todos los experimentos, ejecuciones y análisis de métricas fueron verificados y validados sobre el entorno local del equipo.